

TRABALHO FINAL

Módulo 6 — Apache Hop

Projeto ETL, integração de dados, indicadores e dashboard

Formato	Individual ou em grupo de até 5 integrantes
Prazo de desenvolvimento	Projeto planejado para ser realizável em até 3 dias
Apresentação	24/08/2026 (segunda-feira), para toda a turma
Tempo por apresentação	Máximo de 10 minutos

Objetivo do trabalho

Desenvolver uma solução de integração de dados utilizando Apache Hop, partindo de um dataset público, tratando seus dados, integrando-os a um banco de dados, estruturando pipelines e workflows e produzindo indicadores que possam ser apresentados em um dashboard.

1. Proposta geral

O trabalho final deverá demonstrar, de forma prática, o uso do Apache Hop para transformar dados brutos em informação estruturada e útil para análise. O foco não está em construir uma aplicação grande, mas em demonstrar corretamente o processo de ETL, a organização do fluxo, o tratamento dos dados, a persistência em banco e a geração de indicadores.

Dataset público → Tratamento → Integração → Banco de Dados → Indicadores → Dashboard

2. Formação dos grupos

- O trabalho pode ser realizado de forma individual.
- Os grupos podem possuir até 5 integrantes.
- Todos os integrantes devem conhecer a solução desenvolvida e estar aptos a explicar as decisões tomadas.
- A divisão interna das atividades fica a critério do grupo, mas o resultado apresentado deve formar uma solução única e integrada.

3. Escolha do dataset

O grupo pode escolher uma das bases sugeridas neste documento ou utilizar um dataset diferente, encontrado na internet. A escolha de uma base alternativa é permitida desde que o projeto mantenha a mesma estrutura mínima exigida.


Dataset diferente é permitido

A utilização de outro dataset não reduz nem altera os requisitos do trabalho. É obrigatório definir um problema, realizar tratamento de dados dentro da pipeline, integrar a solução com banco de dados, produzir indicadores e apresentar uma visualização em dashboard.

4. Requisitos obrigatórios do projeto

- Utilizar um dataset obtido de fonte pública na internet e informar sua origem.
- Definir claramente o problema principal que será investigado ou respondido com os dados.
- Realizar tratamento do dataset dentro de pipeline(s) do Apache Hop. A etapa de tratamento é obrigatória.
- O tratamento deve envolver operações coerentes com a base, como padronização, conversão de tipos, tratamento de nulos, remoção ou separação de dados inválidos, tratamento de duplicidades ou criação de campos derivados.
- Integrar o processo a um banco de dados relacional.
- Criar uma estrutura de tabelas coerente com o problema e explicar o significado das principais tabelas.
- Criar pipeline(s) para ingestão, transformação, integração e persistência dos dados.
- Criar pelo menos um workflow no Apache Hop para organizar/orquestrar a execução do processo.
- Levantar indicadores que respondam ao problema proposto.
- Construir um dashboard para visualização dos resultados.
- Validar o resultado final, conferindo se os dados carregados e os indicadores fazem sentido.

5. Estrutura mínima esperada



A estrutura pode variar conforme o dataset e a solução escolhida. Não é obrigatório que todos os projetos tenham exatamente a mesma quantidade de pipelines ou tabelas, mas todas as etapas essenciais precisam estar representadas.

6. Tratamento e qualidade dos dados

A pipeline não deve apenas transportar os dados da origem para o destino. Ela precisa demonstrar transformação e tratamento.

- conversão e validação de tipos;
- tratamento de campos vazios ou valores especiais;
- padronização de textos e categorias;
- identificação ou eliminação de duplicidades;
- separação de registros rejeitados, quando aplicável;
- criação de novos campos calculados;

- aplicação de regras de classificação ou negócio, quando fizer sentido para o problema.

7. Integração com banco de dados

O banco de dados deve fazer parte efetiva da solução. Não basta apenas criar uma conexão: os dados tratados precisam ser persistidos e utilizados pelo processo.

- Deve existir pelo menos uma tabela destinada aos dados tratados/detalhados.
- É recomendável criar uma tabela de resumo ou indicadores quando isso fizer sentido.
- Tabelas auxiliares de cadastro, classificação ou referência podem ser utilizadas para enriquecimento por lookup.
- O grupo deve ser capaz de explicar as chaves, principais colunas e relacionamento lógico entre as tabelas.
- Deve ser discutido o comportamento do processo em caso de reexecução, principalmente quanto a duplicidades.

8. Indicadores e dashboard

Os indicadores não devem ser escolhidos apenas por estarem disponíveis no dataset. Eles precisam ajudar a responder ao problema definido pelo grupo.

- Recomenda-se trabalhar com pelo menos 5 indicadores relevantes.
- Os indicadores podem envolver totais, médias, taxas, percentuais, rankings, evolução temporal, comparações entre categorias ou outros cálculos coerentes com a base.
- O dashboard deve apresentar os principais resultados de forma visual e compreensível.
- A ferramenta de dashboard pode ser definida pelo grupo, desde que a visualização seja gerada a partir dos dados resultantes do processo desenvolvido.

9. Apresentação final — 24/08/2026

Apresentação obrigatória

Todos os grupos e participantes individuais deverão apresentar o projeto para a turma na segunda-feira, 24/08/2026. Cada apresentação terá duração máxima de 10 minutos.

Não é obrigatório utilizar uma apresentação em PowerPoint. O grupo pode conduzir a apresentação diretamente pelo Apache Hop, banco de dados, dashboard e demais artefatos do projeto. O importante é apresentar o resultado de forma organizada e objetiva.

Pontos que obrigatoriamente devem ser apresentados

- Dataset utilizado e sua origem.
- Problema principal definido pelo grupo.
- Pipeline(s) desenvolvida(s) no Apache Hop.
- Workflow(s) desenvolvido(s) no Apache Hop e o papel de cada etapa.
- Tratamentos e principais regras aplicadas aos dados.
- Indicadores levantados e o que eles representam.
- Integração com banco de dados.
- Estrutura do banco: principais tabelas, suas finalidades e campos relevantes.
- Dashboard e interpretação dos resultados obtidos.

Orientação para os 10 minutos

1 min	Contexto, dataset e problema
-------	------------------------------

3 min	Pipeline(s), tratamento e workflow(s)
2 min	Banco de dados e estrutura criada
3 min	Indicadores e dashboard
1 min	Conclusão: principal resultado e aprendizado

Foco da apresentação

Evite gastar tempo explicando toda a teoria utilizada. Mostre o que foi construído, quais decisões foram tomadas, como os dados foram processados e qual resultado foi obtido.

10. Entrega no Google Classroom

Cada grupo deverá enviar pelo Google Classroom um relatório contendo evidências do trabalho desenvolvido. O relatório deve registrar, por meio de prints e explicações objetivas, os mesmos pontos obrigatórios da apresentação.

Estrutura sugerida do relatório

1. Identificação do grupo e integrantes.
2. Link e descrição do dataset utilizado.
3. Descrição do problema principal.
4. Descrição da arquitetura da solução.
5. Evidências e explicações das pipelines.
6. Evidências e explicações dos workflows.
7. Tratamentos de dados implementados.
8. Estrutura do banco de dados, tabelas e principais campos.
9. Indicadores calculados.
10. Prints do dashboard.
11. Validação dos resultados.
12. Conclusão do grupo: o que os dados permitiram observar e quais foram as principais decisões técnicas.

Não é necessário produzir um relatório extenso. A prioridade é que as evidências sejam legíveis e que cada print esteja acompanhado de uma explicação do que está sendo demonstrado.

11. Sugestões de projetos e datasets

As propostas abaixo são referências de escopo. O grupo pode utilizar diretamente uma delas ou adaptá-la. Os links direcionam para as páginas oficiais dos datasets no UCI Machine Learning Repository.

Projeto 1 — Monitoramento de Manutenção Industrial

Dataset	AI4I 2020 Predictive Maintenance Dataset Acessar base oficial (UCI Machine Learning Repository)
Problema sugerido	Quais tipos de produto e condições operacionais concentram mais ocorrências de falha e maior desgaste?
Fluxo sugerido	CSV → tratamento e conversão → classificação de desgaste/condição → enriquecimento → banco detalhado → resumo por tipo/falha → dashboard.

Indicadores possíveis	Taxa de falha; falhas por tipo; desgaste médio; torque médio; temperatura média; registros em faixa crítica; ranking de condições com maior ocorrência de falhas.
Complexidade	Média

Projeto 2 — Análise de Vendas de E-commerce

Dataset	Online Retail Acessar base oficial (UCI Machine Learning Repository)
Problema sugerido	Quais produtos, países e períodos concentram maior faturamento, volume de vendas e cancelamentos?
Fluxo sugerido	Planilha → limpeza → identificação de cancelamentos → cálculo de valor total → enriquecimento geográfico/categórico → banco → agregações → dashboard.
Indicadores possíveis	Faturamento; quantidade vendida; ticket médio; número de pedidos; taxa de cancelamento; produtos mais vendidos; países com maior faturamento; evolução mensal.
Complexidade	Média/Alta

Projeto 3 — Mobilidade Urbana e Bicicletas Compartilhadas

Dataset	Bike Sharing Acessar base oficial (UCI Machine Learning Repository)
Problema sugerido	Em quais horários, dias e condições climáticas ocorre maior ou menor demanda por bicicletas?
Fluxo sugerido	CSV → tratamento de data/hora → mapeamento de estação/clima → classificação de demanda → banco → agregações horárias/diárias → dashboard.
Indicadores possíveis	Total de locações; média por hora; demanda por estação; demanda em dias úteis; demanda em feriados; horários de pico; usuários casuais x registrados.
Complexidade	Baixa/Média

Projeto 4 — Monitoramento de Qualidade do Ar

Dataset	Air Quality Acessar base oficial (UCI Machine Learning Repository)
Problema sugerido	Em quais períodos ocorreram as piores condições registradas e quais variáveis ambientais estavam associadas a esses períodos?
Fluxo sugerido	CSV/Excel → tratamento de valores ausentes/especiais → conversão de data/hora → regras de classificação → banco detalhado → resumo temporal → dashboard.
Indicadores possíveis	Médias por período; máximos; quantidade de registros inválidos; horas em condição crítica; temperatura média; umidade média; evolução diária/mensal.
Complexidade	Média

Projeto 5 — Demanda de Bicicletas e Condições Meteorológicas em Seul

Dataset	Seoul Bike Sharing Demand Acessar base oficial (UCI Machine Learning Repository)
Problema sugerido	Quais condições climáticas, horários e situações operacionais estão associadas aos períodos de maior utilização do serviço?
Fluxo sugerido	CSV → tratamento → classificação de temperatura/chuva/demanda → banco → resumo por hora/estação/condição climática → dashboard.
Indicadores possíveis	Bicicletas alugadas; demanda média com e sem chuva; demanda por temperatura; uso em feriados; horários de pico; demanda por estação; percentual de períodos com alta demanda.
Complexidade	Baixa/Média

12. Exemplos de classificação e regras de negócio

Uma forma de tornar o projeto mais analítico é criar campos derivados a partir dos dados originais. Essas classificações não são obrigatórias em todos os projetos, mas são recomendadas quando ajudam a responder ao problema.

Tema	Campo original	Exemplo de campo derivado
Manutenção	tool_wear	BAIXO / MODERADO / CRÍTICO
Bicicletas	temperatura	FRIO / AMENO / QUENTE
E-commerce	valor_total	BAIXO / MÉDIO / ALTO

Importante sobre classificações

Se o grupo criar faixas ou regras sem uma referência externa, deve declarar que se trata de uma classificação analítica definida para o projeto. Caso utilize limites provenientes de norma, artigo ou outra fonte, essa referência deve ser informada.

13. Critérios técnicos de verificação

Aspecto	Pergunta de verificação
Problema	Está claro o que o grupo pretende analisar ou responder?
Fonte	O dataset e sua origem estão identificados?
Tratamento	Há transformações reais realizadas dentro do Apache Hop?
Banco	Os dados tratados são persistidos e a estrutura foi explicada?
Pipelines	Os fluxos possuem lógica coerente e são executáveis?
Workflows	Existe orquestração adequada das etapas?
Indicadores	Os indicadores ajudam a responder ao problema?
Dashboard	Os principais resultados são visualizados de forma clara?

Validação	O grupo verificou contagens, dados inválidos, duplicidades e resultados?
Comunicação	A apresentação é objetiva e demonstra o que foi efetivamente construído?

14. Checklist antes da entrega

- ☐ Dataset e link da fonte definidos.
- ☐ Problema principal descrito.
- ☐ Pipeline de ingestão funcionando.
- ☐ Tratamento de dados implementado dentro do Apache Hop.
- ☐ Integração com banco de dados funcionando.
- ☐ Estrutura das tabelas documentada.
- ☐ Workflow criado e testado.
- ☐ Indicadores calculados.
- ☐ Dashboard finalizado.
- ☐ Reexecução e possíveis duplicidades verificadas.
- ☐ Relatório com prints e explicações preparado.
- ☐ Apresentação ensaiada para caber em até 10 minutos.

Pergunta final que todo grupo deve saber responder

Se o pipeline for executado novamente com a mesma fonte de dados, o que acontecerá? A solução duplicará registros, atualizará os existentes ou possui alguma estratégia de controle de reproprocessamento?